



第4章 朴素贝叶斯法

主要内容

- 朴素贝叶斯法的学习和分类
- 朴素贝叶斯法的参数估计



4.1朴素贝叶斯法的学习和分类

最大似然估计：

假设外观相同的两个箱子，甲箱中有99个白球，1个黑球，乙箱中有99个黑球，1个白球，若某次取出来的是白球，请问最有可能是从哪个箱子取出的？

基本思想

首先基于**特征条件的独立**假设，学习输入/输出的联合概率；
然后基于此模型，对于给定输入 x ，利用贝叶斯定理，求出**后验概率最大**的输出 y 。

1、基本方法

输入空间 $X \in R^n$ 为n维向量的集合，输出空间为类标记集合 $Y = \{c_1, c_2, \dots, c_n\}$ ，输入特征向量 $x \in X$ ，输出为类标签 $y \in Y$ ， X 是在输入空间上的随机向量， Y 是在输出空间 Y 上的随机变量， $P(X, Y)$ 是 X 和 Y 的联合概率分布，训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ，由 $P(X, Y)$ 独立同分布产生。

朴素贝叶斯通过训练数据集学习联合概率分布 $P(X, Y = c_k)$ 。

学习先验概率分布 $P(Y = c_k), k = 1, 2, \dots, K$ 和条件概率分布 $P(X = x | Y = c_k)$ 。

$$P(X, Y = c_k) = P(Y = c_k) P(X = x | Y = c_k)$$

$$= P(Y = c_k) P(X^{(1)} = x^{(1)}, X^{(2)} = x^{(2)}, \dots, X^{(n)} = x^{(n)} | Y = c_k)$$

条件概率分布 $P(X=x|Y=c_k)$ 是 n 维的条件概率，有指数级的参数，求解困难

假设 $x^{(j)}$ 可能值有 S_j 个， $j=1,2,\dots,n$ ， Y 可能取值有 K 个，参数个数 $K \prod_{j=1}^n S_j$

条件独立性假设： $P(X = x \mid Y = c_k)$

$$= P(X^{(1)} = x^{(1)}, X^{(2)} = x^{(2)}, \dots, X^{(n)} = x^{(n)} \mid Y = c_k)$$

$$= \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k)$$

条件独立性假设：说明用于分类的特征，在类别确定的条件下是条件独立的。

简化了朴素贝叶斯法，牺牲了分类准确性。

后验概率 $P(Y=c_k|X=x)$ 的计算：

$$P(Y = c_k | X = x) = \frac{P(X = x | Y = c_k)P(Y = c_k)}{\sum_k P(X = x | Y = c_k)P(Y = c_k)}$$

代入独立假设条件

$$P(Y = c_k | X = x) = \frac{P(Y = c_k)\prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k)\prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}$$

朴素贝叶斯分类器

$$y = f(x) = \arg \max_{c_k} \frac{P(Y = c_k)\prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k)\prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}$$

对于所有的 c_k ，分母都相同。

$$y = \arg \max_{c_k} P(Y = c_k)\prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$

2、后验概率最大化

朴素贝叶斯法将实例分到后验概率最大的类中，等价于期望风险最小化，假设选择0-1损失函数， $f(X)$ 为决策函数：

$$L(Y, f(X)) = \begin{cases} 1, Y \neq f(X) \\ 0, Y = f(X) \end{cases}$$

期望风险函数

$$R_{\text{exp}}(f) = E[L(Y, f(X))]$$

条件期望

$$R_{\text{exp}}(f) = E_X \sum_{k=1}^K [L(c_k, f(X))] P(c_k | X)$$

只需对 $X=x$ 逐个极小化，得：

$$\begin{aligned} f(x) &= \arg \min_{y \in Y} \sum_{k=1}^K [L(c_k, y)] P(c_k \mid X = x) \\ &= \arg \min_{y \in Y} \sum_{k=1}^K P(y \neq c_k \mid X = x) \\ &= \arg \min_{y \in Y} \sum_{k=1}^K (1 - P(y = c_k \mid X = x)) \\ &= \arg \max_{y \in Y} \sum_{k=1}^K P(y = c_k \mid X = x) \end{aligned}$$

后验概率最大化准则：

$$f(x) = \arg \max_{c_k} P(c_k \mid X = x)$$



4.2朴素贝叶斯法的参数估计

1、极大似然估计

先验概率 $P(Y=c_k)$ 的极大似然估计：

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

设第 j 个特征 $x^{(j)}$ 可能取值的集合为 $\{a_{j1}, a_{j2}, \dots, a_{jS_j}\}$, 条件概率的极大似然估计：

$$P(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

$j=1, 2, \dots, n$; $l=1, 2, \dots, S_j$; $k=1, 2, \dots, K$, $x_i^{(j)}$ 是第 i 个样本的第 j 个特征 ,
 a_{jl} 是第 j 个特征可能取的第 l 个值

2、学习与分类算法

输入：训练数据 $T=\{(x_1,y_1),(x_2,y_2),\dots,(x_N,y_N)\}$ ，其中 $x_i=(x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$ ， $x_i^{(j)}$ 是第 i 个样本的第 j 个特征， $x_i^{(j)} \in \{a_{j1}, a_{j2}, \dots, a_{js_j}\}$ ， a_{jl} 是第 j 个特征可能取得的第 l 个值， $j=1,2, \dots, n$ ， $l=1,2, \dots, S_j$ ， $y_i \in \{c_1, c_2, \dots, c_k\}$ ，实例 x ；
输出：实例 x 的分类

(1) 计算先验概率和条件概率

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

$$P(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

$$j=1,2,\dots,n; l=1,2,\dots,S_j; k=1,2,\dots,K$$

(2) 对于给定实例 $x=(x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$, 计算

$$P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k) \quad k=1,2,..K$$

(3) 确定实例 x 的类

$$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k)$$

3、贝叶斯估计

用极大似然估计可能会出现所要估计的概率值为0的情况，这时会影响到后验概率的计算结果，使分类产生偏差.解决这一问题的方法是采用贝叶斯估计

条件概率的贝叶斯估计和先验概率的贝叶斯估计

$$P_{\lambda}(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$$

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}$$

$$j=1,2,\dots,n ; l=1,2,\dots,S_j ; k=1,2,\dots,K$$

【例4.1】用训练数据学习一个朴素贝叶斯分类器，并确定 $x=(2,S)^T$ 的类标记 y ， $X(1), X(2)$ 为特征，取值的集合分别为 $A1=\{1,2,3\}$ ， $A2=\{S,M,L\}$ ， Y 为类标记， $Y \in C=\{1,-1\}$ 。按照拉普拉斯平滑估计概率（ $\lambda=1$ ）

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	1

解： $A1=\{1,2,3\}$ ， $A2=\{S,M,L\}$ ， $C=\{1,-1\}$ ，
计算条件概率和先验概率下的贝叶斯估计：

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}$$

$$P(Y=1)=10/17, P(Y=-1)=7/17$$

$$P_{\lambda}(X^{(j)} = a_{j1} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{j1}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$$

$$P(X^{(1)}=1|Y=1)=3/12, P(X^{(1)}=2|Y=1)=4/12, P(X^{(1)}=3|Y=1)=5/12$$

$$P(X^{(2)}=S|Y=1)=2/12, P(X^{(2)}=M|Y=1)=5/12, P(X^{(2)}=L|Y=1)=5/12$$

【例4.1】用训练数据学习一个朴素贝叶斯分类器，并确定 $x=(2,S)^T$ 的类标记 y ， $X(1), X(2)$ 为特征，取值的集合分别为 $A1=\{1,2,3\}$ ， $A2=\{S,M,L\}$ ， Y 为类标记， $Y \in C=\{1,-1\}$ 。按照拉普拉斯平滑估计概率（ $\lambda=1$ ）

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	1

$$P(X^{(1)}=1|Y=-1)=4/9, \quad P(X^{(1)}=2|Y=-1)=3/9, \quad P(X^{(1)}=3|Y=-1)=2/9$$

$$P(X^{(2)}=S|Y=-1)=4/9, \quad P(X^{(2)}=M|Y=-1)=3/9, \quad P(X^{(2)}=L|Y=-1)=2/9$$

对于给定 $x=(2,S)^T$ 计算：

$$P(Y=1)P(X^{(1)}=2|Y=1)P(X^{(2)}=S|Y=1)=0.0327$$

$$P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1)=0.0610$$

由于 $P(Y=-1)P(X^{(1)}=2|Y=-1)P(X^{(2)}=S|Y=-1)$ 值最大，所以 $y=-1$

伯努利模型

在伯努利模型中，每个特征的取值是布尔型的(true和false)，或者1和0。
即一个特征有在一个样本中是否出现。

先验概率 $p(c)$ =属于类c样本总数/整个训练样本的样本总数

类条件概率 $p(t_k|c)=(\text{类c下包含特征}t_k\text{的样本总数}+1)/(\text{类c下的样本总数}+2)$

	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15
$X^{(1)}$	1	1	1	1	1	2	2	2	2	2	3	3	3	3	3
$X^{(2)}$	S	M	M	S	S	S	M	M	L	L	L	M	M	L	L
Y	-1	-1	1	1	-1	-1	-1	1	1	1	1	1	1	1	1

$P(Y=1)=?$, $P(Y=-1)=?$

$P(X^{(1)}=1|Y=1)=?$, $P(X^{(1)}=1|Y=-1)=?$, $P(X^{(1)}=1|Y=1)=?$

$P(X^{(2)}=S|Y=1)=?$, $P(X^{(2)}=M|Y=1)=?$, $P(X^{(2)}=L|Y=1)=?$

高斯模型

假设男性和女性的身高、体重和脚掌是正态分布，通过样本分别计算出均值 μ 和方差 σ^2

身高(英寸)	体重(磅)	脚掌(英寸)	性别
6	180	12	男
5.92	190	11	男
5.98	170	12	男
5.92	165	10	男
5	100	6	女
5.5	150	8	女
5.42	130	7	女

预测某人身高为6英尺，体重179磅，脚掌10英寸的性别。则：

$$p(\text{height}|\text{male}) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(6-\mu)^2}{2\sigma^2}}$$

据此可以求出其他特征的条件概率，从而最终推断出该人是男性还是女性。

朴素贝叶斯分类的优缺点

优点：

- (1) 算法逻辑简单,易于实现
- (2) 分类过程中时, 开销小 (假设特征相互独立, 只会涉及到二维存储)

缺点：

在属性个数比较多或者属性之间相关性较大时, 分类效果不好。