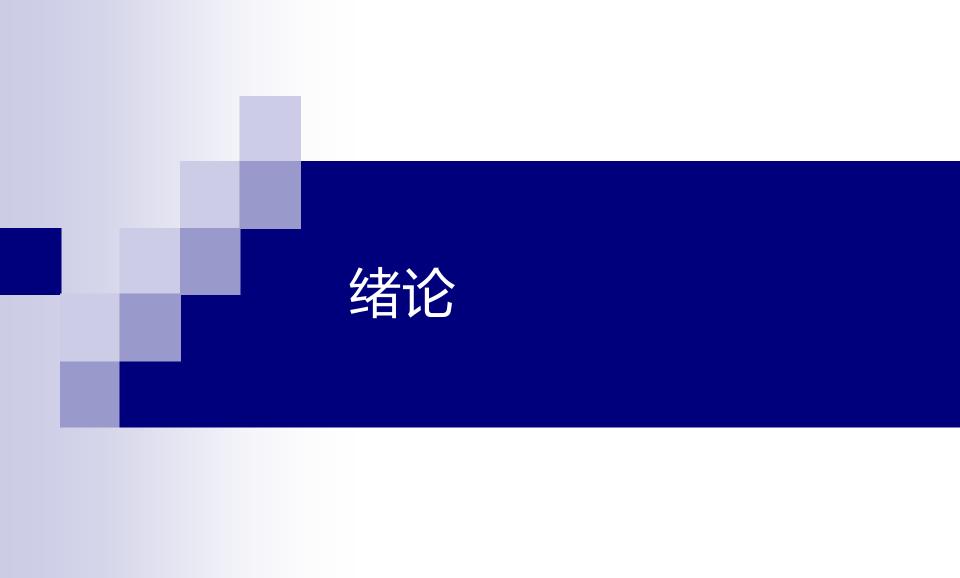
机器学习技术与应用

教师:黄俊

手机:13708083857

邮箱: jhuang@uestc.edu.cn

QQ群:1043072373



主要内容

- 技术背景
- 相关学科
- 发展历程
- 数据特征
- 课程特点
- 成绩构成

一、技术背景

Question: What's the classification the images belong to? ladles



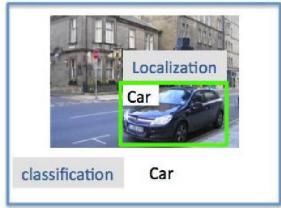
ImageNet Challenge 2012

Task 1: Classification



- Predict a class label
- 5 predictions / image
- 1000 classes
- 1,200 images per class for training
- Bounding boxes for 50% of training.

Task 2: Detection (Classification + Localization)



- Predict a class label and a bounding box
- 5 predictions / image
- 1000 classes
- 1,200 images per class for training
- Bounding boxes for 40% of training.

Task 3: Fine-grained classification



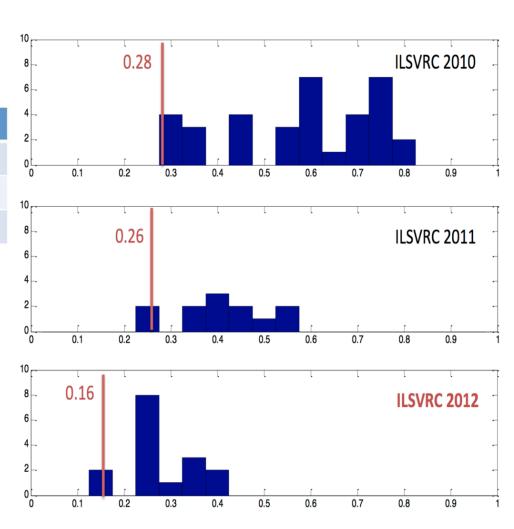
- Predict a class label given a bounding box in test
- · 1 prediction / image
- 120 dog classes (subset)
- ~200 images per class for training (subset)
- Bounding boxes for 100% of training



Promising techniques

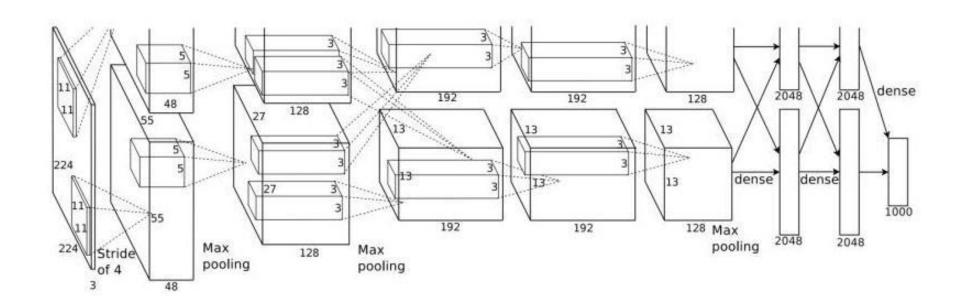
Method	Year
Locality-constrained Linear Coding	ILSVRC 2010
Improved Fisher Vectors	ILSVRC 2011
Convolutional Neural Networks	ILSVRC 2012

Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton, University of Toronto 2012



M

Convolutional Neural Network



Alex Krizhevsky, Ilya Sutskever, Geoffrey Hinton, University of Toronto 2012

ImageNet Progress

2015年:微软的神经网络系统错误率为4.94%,低于人类测试者的5.1%

	layers	error(top 5)	
AlexNet	8	15%	2012
VGGNet	19	7.32%	2014
GooleNet	22	6.66%	2014
MSRA	152	3.5 7 %	2016

Top-5 = (正确标记 不在 模型输出的前5个最佳标记中的样本数)/总样本数

Alphago



大数据机器学习时代

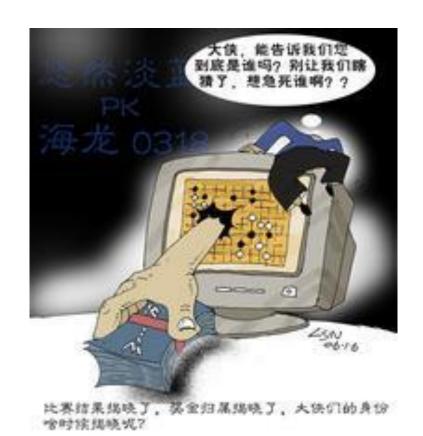
机器学习(维基百科):

机器学习是近20多年兴起的一门多领域交叉学科,涉及概率论、统计学、 逼近论、凸分析、算法复杂度理论等多门学科。

机器学习理论主要是设计和分析一些让计算机可以自动"学习"的算法。机器学习算法是一类从数据中自动分析获得规律,并利用规律对未知数据进行预测的算法。

因为学习算法中涉及了大量的统计学理论,机器学习与统计推断学联系尤为密切,也被称为统计学习理论。

Game





1997年IBM公司的深蓝战胜了世界象棋大师卡斯帕罗夫,运算速度为每秒2亿步棋,其计算能力为11.38GFLOPS

Text to speech and speech recognition





3D 体感游戏





Bioinformatics

Gene

gaactcgcttgtttgggggattggctggctaatcgcggctagatcccaggcggtataaccttttcgc :eggetegagtatttgttgtgecatgttggttaegatggcaategeggtaeagttatgeaaatgagea eggaetgaaaagtgeggagagaaacccaaaaacaga, gegegeaaagegeegttaatatgegaacte :getgateaagtatteagegetgegetagattegae/gattgaategageteaatagaeteaaeag/ae statgegeaatgtgeaattegettacettetegtt/gegggteaggaacteceagatgggaatggee/a sttgegtaeteegeaetaeaeggagagtteaggggattegtgeteegtgatetgtgateegtgtteeg igattateaettggttteggtggetageeaagtggetttettetgteegaegeaettaattgaattaa :tteteggeaagatgggggggteagteggtetal (MA) (aggggggggegace) gtegateacgaaaacg :cggacagcgctggcgctccacacgtatttaagctttgagatcggctgtgg jegeaegtegatgeeateggggaattggaaeeteaatgtgtgggaatgtttaaatattetgtgttagg settgggeaaaaggettaageaegaeteeeagteeeeettaeatttgtetteetaageeeetggage gagtegaacateagtgaggcattgcaaaatttcaaagtcaagtttgcgtcgtcatcgcgtctgagt ctaattaagcaaataaacatatcaaattccagaatgcgacggccatcatcctgtttgggaattc jaccccataaatttgataagcccgagctcgctgcgttgagtcagccaccccacatccccaaatccccg attecattegattecateegggaatgegataaagaaaggetetgateeaageaaetgeaateeggatt :atcgtgcgatagaggatgagtcatttccatatggccgaaatttattatgtttactatcgtttttaga :teeggatatatttgaaacacactagctagcagtgttggtaagttacatgtatttctataatgtcata

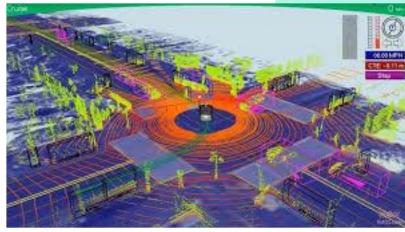
Quantitative trading



Robotic Control







再现古代陶瓷工艺



二、相关学科

机器学习相关概念

人工智能

机器学习

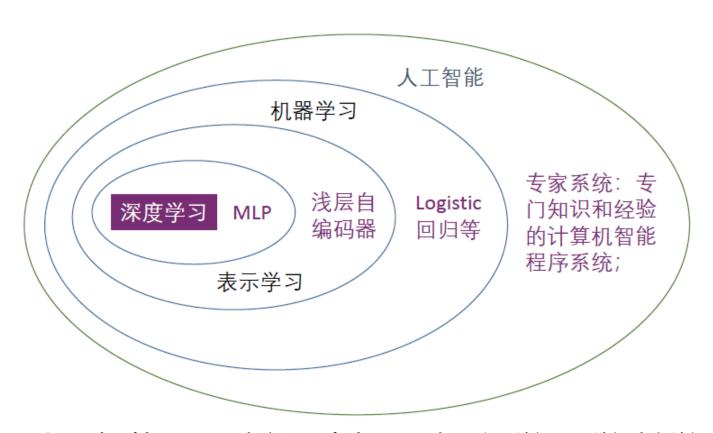
深度学习

数据挖掘

计算机视觉

统计学习

人工智能/机器学习/深度学习

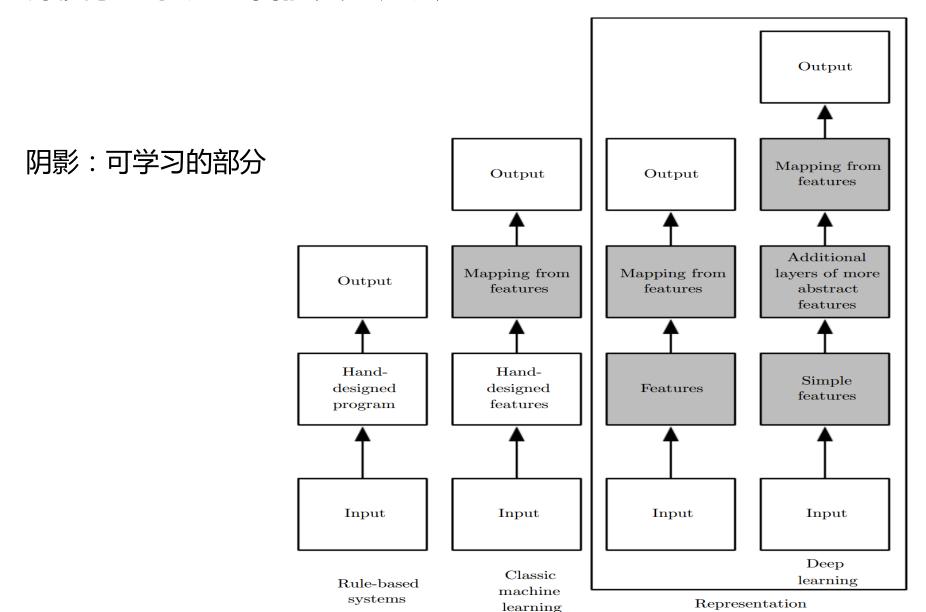


人工智能:是科学,为机器赋予视觉/听觉/触觉/推理

机器学习:人工智能的计算方法



深度学习和人工智能其它方法



learning



机器学习和数据挖掘

数据挖掘

数据分析技术

数据管理技术

机器学习

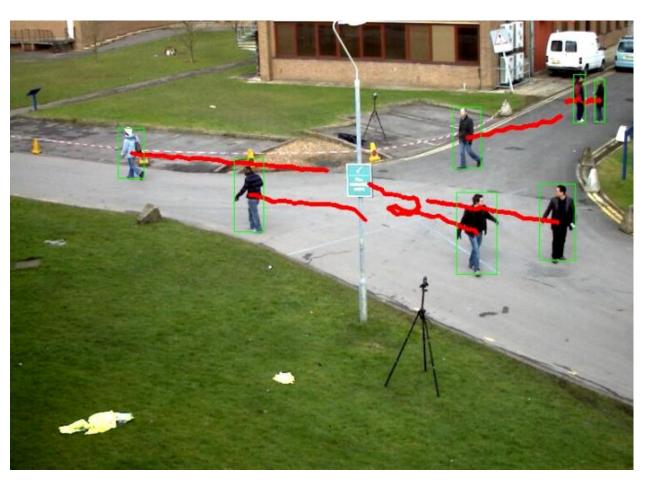
数据库

机器学习的一个形象描述



机器学习和计算机视觉

MOT多目标跟踪比赛



计算机视觉是机器学习最重要的应用



机器学习和统计学习

Simon Blomberg:

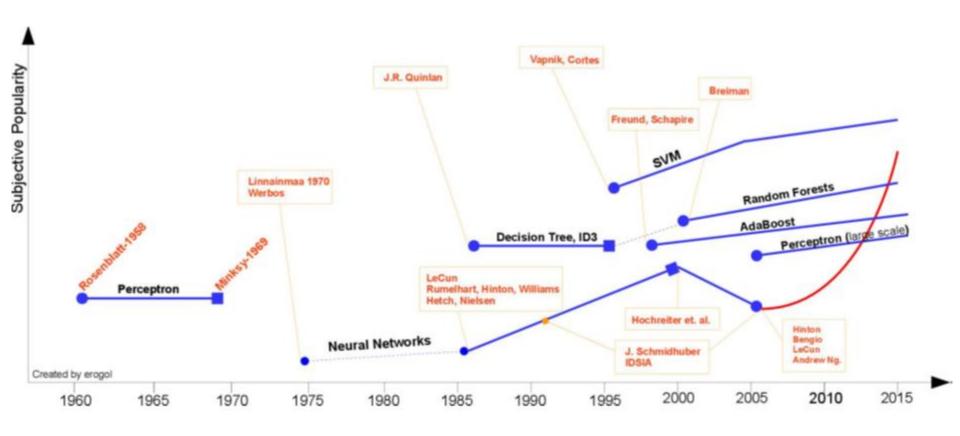
From R's fortunes package: To paraphrase provocatively, 'machine learning is statistics minus any checking of models and assumptions

Andrew Gelman:

In that case, maybe we should get rid of checking of models and assumptions more often. Then maybe we'd be able to solve some of the problems that the machine learning people can solve but we can't!

机器学习 = 统计学习 - 模型和假设的检验

三、发展历程



四、数据特征

(1)与日俱增的数据量:Facebook

facebook月活跃用户接近8.5亿

每天上传的照片总量为2.5亿张

4.25亿移动用户

1000亿个connections

Zygna游戏为facebook总收入贡献了12%

57%的用户为女性用户



Tencent

QQ:月活跃用户超8亿,最高同时在线1.9亿;在线人际关系链超1000亿;

微信:月活跃用户超3.5亿;日均消息量超50亿;

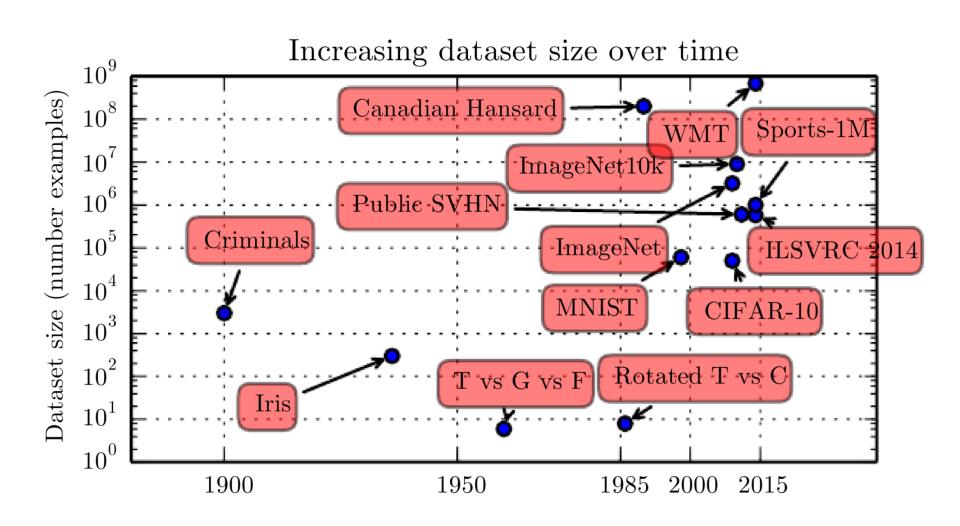
空间:月活跃用户超6亿;日均相册上传超过4亿;

游戏:腾讯游戏月活跃用户4.5亿;手机游戏月活跃用户近2亿;

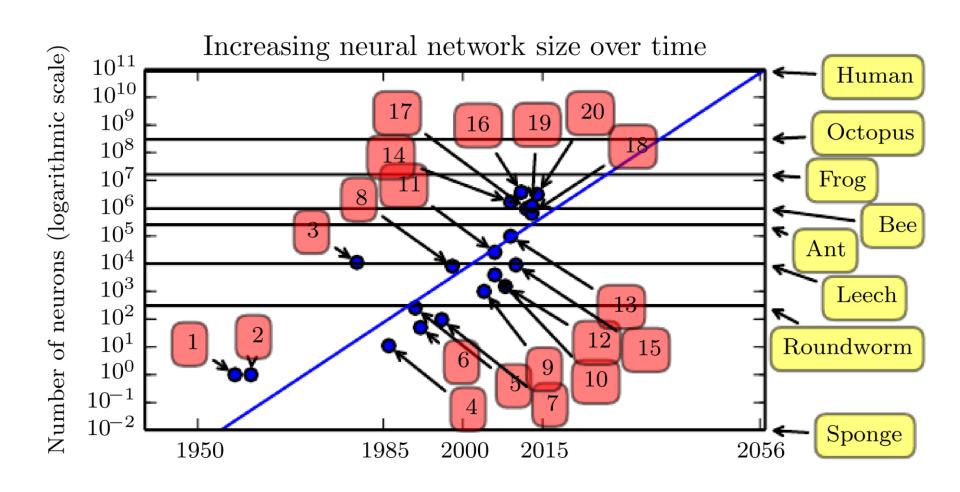
网站:日均浏览量PC侧超17亿;手机侧近13亿;最高日接入消息条数8000亿;

日接入数据量200TB;并发分拣业务接口10000个。

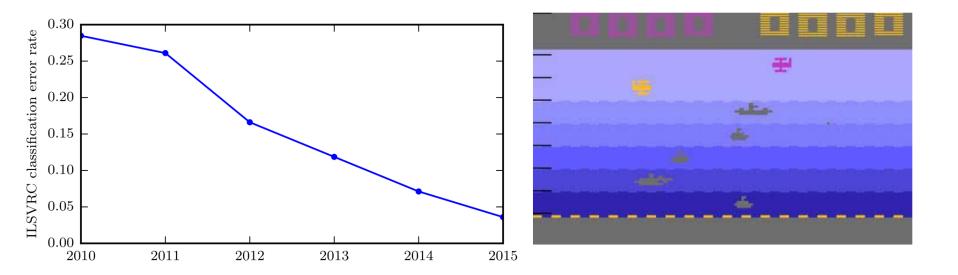
(2)实验数据量的增加



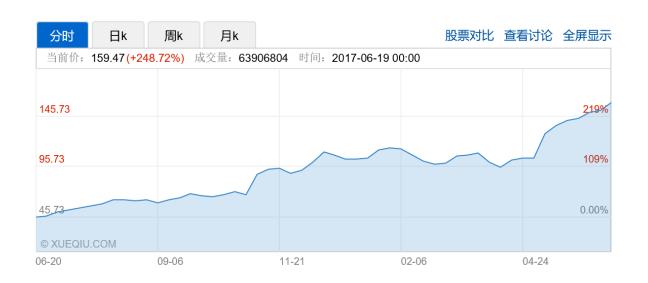
(3)与日俱增的神经网络模型规模

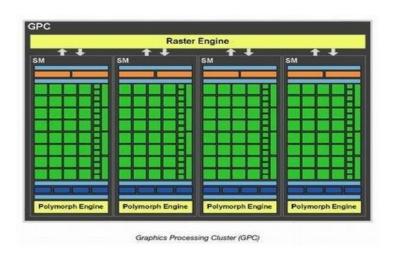


(4)与日俱增的精度、复杂度和对现实世界的冲击



(5) GPU (Graphic Processing Unit)





TESLA P100 ACCELERATORS



5.3 TF DP · 10.6 TF SP · 21 TF HP 720 GB/sec Memory Bandwidth, 16 GB

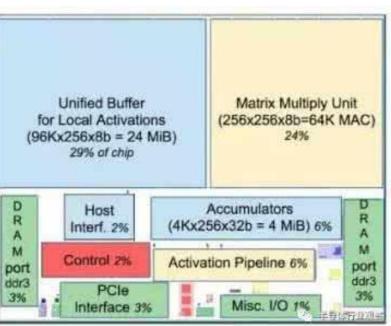
Tesla P100 for PCIe-Based Servers



4.7 TF DP • 9.3 TF SP • 18.7 TF HP Config 1: 16 GB, 720 GB/sec Config 2: 12 GB, 540 GB/sec

TPU Tensor Processing Unit





(6)深度学习框架

TensorFlow

Pytorch

Caffe

CNTK

Keras

MXNet

Theano

Scikit-learning

Spark MLlib

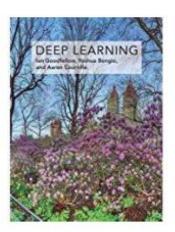
四、课程特点

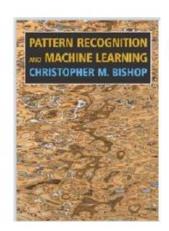
目的是培养学生深入理解机器学习理论基础,牢固掌握机器学习基本方法,并能够解决实际问题等综合能力。

课程重点在机器学习算法背后的数学原理,便于更好理解算法的特点和应用。











自学课程

Python数据分析基础

- 1 https://www.python.org/
- 2 https://www.numpy.org.cn/
- 3 https://www.pypandas.cn/
- 4 https://matplotlib.org/
- 5 https://www.anaconda.com/
- 6 https://scikit-learn.org/stable/



基础课程

高等数学:函数的极值、函数的性质(极限、上界与下界、导数、定积分、 单调性、极值、凹凸性、泰勒公式、偏导数、梯度、高阶偏导数、链式法则)

线性代数:向量、矩阵、特征值与特征向量、二次型、特征值分解、奇异值 分解

概率论和数理统计:随机事件与概率、条件概率与独立性、贝叶斯公式、 离散型随机变量与连续型随机变量、数学期望、方差、协方差、常用的概 率分布、参数估计

最优化方法:梯度下降法(随机梯度下降法、最速下降法、梯度下降法的改进型)、牛顿法(拟牛顿法)、凸优化、拉格朗日乘数法、KKT条件、拉格朗日对偶

五、成绩构成

成绩构成: 平时10%, 作业+课堂练习

实验40%,报告+实验课考勤

期末50%, 闭卷考试